Proyecto 2 - Machine Learning

Luciana Yangali Cáceres, Gabriel Frisancho, Yuri Abel, Angel triveño

***Resumen*—En esta sección teórica se presentan los fundamentos de algoritmos de agrupamiento, incluyendo K-means, GMM, clustering jerárquico y clustering basado en densidad (DBSCAN). Se incluyen preguntas y ejemplos que deben resolverse para comprender los conceptos matemáticos y prácticos de cada método.**

***Index Terms*—Clustering, K-means, Gaussian Mixture Model, DBSCAN, clustering jerárquico, aprendizaje no supervisado.**

I. Parte Teórica (30 pts)

I-A. Fundamentos de K-means y GMM (10 pts)

Sea un dataset

$$\mathcal{D} = \{x^{(1)}, x^{(2)}, \ldots, x^{(N)}\}, \quad x^{(i)} \in \mathbb{R}^d.$$

I-A1. 1. Función objetivo de K-means: La función objetivo de K-means se define como:

$$J(\mu_1, \ldots, \mu_k, z) = \sum_{i=1}^{N} \sum_{j=1}^{K} z_{ij} \|x^{(i)} - \mu_j\|^2,$$

donde $z_{ij} \in \{0, 1\}$ indica la asignación de los puntos a clusters.

Instrucciones: Explique por qué esta función nunca aumenta durante las iteraciones del algoritmo y por qué esto **no garantiza** encontrar el óptimo global.

Respuesta: La función objetivo J nunca aumenta durante las iteraciones del algoritmo K-means porque el algoritmo es una forma de optimización por bloques que minimiza J en dos pasos alternantes, y cada paso garantiza una reducción (o, en el peor caso, ningún cambio) en J.

Comenzando con el primero paso que es el de Asignación (Actualización de z_{ij}), tenemos que los centroides (μ_j) se mantienen fijas, y se reasignan los puntos a los clústeres. Un punto $\mathbf{x}^{(i)}$ se asigna al centroide μ_j que minimiza la distancia euclidiana al cuadrado:

$$z_{ij} = 1 \text{ si } j = \arg\min_k \|\mathbf{x}^{(i)} - \mu_k\|^2$$

Dado que cada punto se reasigna a su centroide más cercano, la contribución de ese punto a la suma total J se minimiza, o al menos se mantiene igual. Por lo tanto, la función J para el conjunto completo de datos no puede aumentar.

Asimismo, en el segundo paso que es el de actualización de μ_j, se sabe que las asignaciones (z_{ij}) se mantienen fijas, y se recalculan los centroides. El nuevo centroide μ_j se calcula como la media (promedio) aritmética de todos los puntos asignados a ese clúster j:

$$\mu_j = \frac{\sum_{i=1}^{N} z_{ij} \mathbf{x}^{(i)}}{\sum_{i=1}^{N} z_{ij}}$$

Trabajo realizado como parte del curso de Machine Learning en UTEC.

Se demuestra en cálculo multivariable que la media de un conjunto de puntos es el único punto que minimiza la suma de las distancias cuadradas a ese conjunto de puntos. Como μ_j es el minimizador único de la contribución de su clúster a J, la función objetivo no puede aumentar en este paso.

Dado que ninguno de los dos pasos aumenta la función J, el algoritmo K-means garantiza la convergencia a un mínimo local.

I-A2. 2. Comparación K-means vs GMM: **Instrucciones:** Compare K-means y Modelos de Mezclas Gaussianas (GMM) matemáticamente, indicando:

- Suposiciones sobre la forma y tamaño de los clusters.
- Ejemplo de un conjunto de datos donde GMM podría superar a K-means.

I-B. Agrupamiento Jerárquico (10 pts)

Sea un dataset

$$\mathcal{D} = \{x^{(1)}, x^{(2)}, \ldots, x^{(N)}\}, \quad x^{(i)} \in \mathbb{R}^d.$$

I-B1. 1. Métricas de enlace (5 pts): **Instrucciones:** Defina matemáticamente las métricas de distancia entre clusters:

- Enlace simple
- Enlace completo
- Enlace promedio

Respuesta:

Sea A y B dos clústeres compuestos por puntos $x_i \in A$ y $y_j \in B$, con $i = 1, \ldots, |A|$ y $j = 1, \ldots, |B|$. Denotemos por $\|\cdot\|$ la norma euclidiana en $\mathbb{R}^d$. Las principales métricas de enlace se definen de la siguiente manera:

- **Enlace simple (single link):** La distancia entre dos clústeres se define como la distancia mínima entre cualquier par de puntos, uno de cada clúster:

  $$d_{\text{simple}}(A, B) = \min_{i,j} \|x_i - y_j\|.$$

  Esta métrica tiende a favorecer la formación de clústeres alargados o encadenados, ya que solo considera el par de puntos más cercanos.
- **Enlace completo (complete link):** La distancia se define como la distancia máxima entre cualquier par de puntos de los dos clústeres:

  $$d_{\text{complete}}(A, B) = \max_{i,j} \|x_i - y_j\|.$$

  Esta métrica genera clústeres más compactos y circulares, evitando la formación de estructuras alargadas.
- **Enlace promedio (average link):** La distancia se define como el promedio de todas las distancias entre pares de puntos, uno de cada clúster:

  $$d_{\text{average}}(A, B) = \frac{1}{|A||B|} \sum_{i=1}^{|A|} \sum_{j=1}^{|B|} \|x_i - y_j\|.$$

Cuadro I
DISTANCIAS EUCLIDIANAS ENTRE PARES DE PUNTOS EN $\mathbb{R}^2$

Pares de puntos	Distancia
$(1,1)-(2,1)$	1
$(1,1)-(5,3)$	$\approx 4{,}47$
$(1,1)-(6,3)$	$\approx 5{,}39$
$(1,1)-(10,5)$	$\approx 9{,}85$
$(2,1)-(5,3)$	$\approx 3{,}61$
$(2,1)-(6,3)$	$\approx 4{,}47$
$(2,1)-(10,5)$	$\approx 8{,}94$
$(5,3)-(6,3)$	1
$(5,3)-(10,5)$	$\approx 5{,}39$
$(6,3)-(10,5)$	$\approx 4{,}47$

Este enfoque proporciona un compromiso entre la sensibilidad a puntos extremos y la formación de clústeres compactos, suavizando el efecto de valores atípicos.

I-B2. 2. Ejemplo práctico (5 pts: **Considere los puntos en $\mathbb{R}^2$:** $(1,1),(2,1),(5,3),(6,3),(10,5)$**. Instrucciones:**

- **Muestre las primeras dos fusiones usando enlace simple**.
- **Explique cómo el resultado podría diferir usando enlace completo.**

Primero, calculamos las distancias euclidianas entre todos los pares de puntos:
La fusión con enlace simple se realiza considerando la distancia mínima entre clústeres:

1. **Primera fusión:** los puntos más cercanos son $(1,1)$ y $(2,1)$ con distancia 1. Se fusionan en un nuevo clúster $C_1 = \{(1,1),(2,1)\}$.
2. **Segunda fusión:** entre los clústeres existentes, el par más cercano es $(5,3)$ y $(6,3)$ con distancia 1. Se fusionan en $C_2 = \{(5,3),(6,3)\}$.

Diferencia usando enlace completo:

Con enlace completo, la distancia entre clústeres se calcula como la máxima distancia entre puntos de cada clúster.

- La primera fusión puede coincidir con enlace simple si los puntos más cercanos también tienen la máxima distancia mínima (en este caso $(1,1)$ y $(2,1)$).
- La segunda fusión podría diferir: al considerar la distancia máxima, los extremos de los clústeres podrían hacer que los pares $(5,3)$ y $(10,5)$ o $(6,3)$ y $(10,5)$ tengan mayor prioridad según la métrica.
- En general, enlace completo tiende a generar clústeres más compactos y evita la formación de cadenas alargadas, mientras que enlace simple puede crear fusiones "en cadena" conectando puntos sucesivamente cercanos.

I-C. Agrupamiento Basado en Densidad (10 pts)

I-C1. 1. Conceptos formales (5 pts): **Instrucciones:** Defina formalmente en DBSCAN los conceptos de:

1. Punto directamente alcanzable por densidad.
2. Punto alcanzable por densidad.
3. Conectividad por densidad.

Respuesta:

1. **Punto directamente alcanzable por densidad.** Sea $\epsilon > 0$ un radio de vecindad y minPts $\in \mathbb{N}$ un umbral de densidad. Un punto x es *directamente alcanzable por densidad* desde un punto y si $x \in N_\epsilon(y)$, donde $N_\epsilon(y)$ es la vecindad de radio ϵ de y, y y es un *punto core* (es decir, $|N_\epsilon(y)| \geq$ minPts).
2. **Punto alcanzable por densidad.** Un punto x es *alcanzable por densidad* desde un punto y si existe una secuencia de puntos $\{p_1, p_2, \ldots, p_n\}$ tal que $p_1 = y$, $p_n = x$ y cada p_{i+1} es directamente alcanzable por densidad desde p_i.
3. **Conectividad por densidad.** Dos puntos x y y son *conectados por densidad* si existe un punto z tal que x es alcanzable por densidad desde z y y es alcanzable por densidad desde z. En otras palabras, ambos puntos pertenecen al mismo cluster definido por densidad.

I-C2. 2. Ejemplo práctico (5 pts): **Instrucciones:** Con un pequeño conjunto de datos, ilustre cómo DBSCAN puede identificar clusters de forma arbitraria y explique por qué K-means fallaría en el mismo conjunto.

Ejemplo: Consideremos el siguiente conjunto de puntos en $\mathbb{R}^2$:

$$\mathcal{D} = \{P_1(1,1), P_2(1,2), P_3(2,1), P_4(2,2), P_5(8,8), P_6(8,9), P_7(9,8), P_8$$

Aplicaremos el algoritmo DBSCAN con los siguientes hiperparámetros:

- Radio de vecindad: $\epsilon = \mathbf{1{,}5}$
- Mínimo de puntos: minPts $= \mathbf{3}$

Análisis de Vecindad y Clasificación: Para demostrar la identificación, calculamos la distancia euclidiana entre puntos clave.

Cuadro II
DISTANCIAS EUCLIDIANAS CLAVE ($\epsilon = \mathbf{1{,}5}$)

Pares de Puntos	Distancia ($\|x_i - x_j\|$)	Clasificación
$P_1(1,1)$ a $P_2(1,2)$	$\sqrt{(1-1)^2+(2-1)^2} = \mathbf{1{,}0}$	$\leq \epsilon$
$P_1(1,1)$ a $P_4(2,2)$	$\sqrt{(2-1)^2+(2-1)^2} = \mathbf{1{,}41}$	$\leq \epsilon$
$P_5(8,8)$ a $P_9(5,5)$	$\sqrt{(5-8)^2+(5-8)^2} = \mathbf{4{,}24}$	$> \epsilon$
$P_1(1,1)$ a $P_9(5,5)$	$\sqrt{(5-1)^2+(5-1)^2} = \mathbf{5{,}66}$	$> \epsilon$

Cálculo del tamaño de las Vecindades ($|N_\epsilon(P)|$):

1. **Punto $P_1(1,1)$:** Sus vecinos a distancia $\leq 1{,}5$ son $\{P_2, P_3, P_4\}$. Por lo tanto, $|N_{1,5}(P_1)| = 4$.
2. **Punto $P_5(8,8)$:** Sus vecinos a distancia $\leq 1{,}5$ son $\{P_6, P_7, P_8\}$. Por lo tanto, $|N_{1,5}(P_5)| = 4$.
3. **Punto $P_9(5,5)$:** Sus vecinos a distancia $\leq 1{,}5$ son solo él mismo. $|N_{1,5}(P_9)| = 1$.

Resultado de DBSCAN:

- **Puntos Núcleo (*Core Points*):** $P_1, P_2, P_3, P_4, P_5, P_6, P_7, P_8$ (ya que sus vecindades tienen $\geq$ minPts $= 3$ puntos).
- **Cluster 1:** El conjunto conectado por densidad $\{\mathbf{P_1}, \mathbf{P_2}, \mathbf{P_3}, \mathbf{P_4}\}$ es identificado como un clúster.
- **Cluster 2:** El conjunto conectado por densidad $\{\mathbf{P_5}, \mathbf{P_6}, \mathbf{P_7}, \mathbf{P_8}\}$ es identificado como otro clúster.
- **Ruido (*Noise Point*):** El punto $P_9(5,5)$ es clasificado como ruido ya que no es un punto núcleo ni es directamente alcanzable por densidad desde ningún punto núcleo ($|N_{1,5}(P_9)| < 3$).

Asimismo, la razón por la que K-means fallaría, se debe a los sigueintes puntos:

- **Suposición de Forma:** K-means asume implícitamente que los clústeres son esféricos, convexos y de tamaño similar (debido a la minimización de la suma de cuadrados). DBSCAN, al basarse en la densidad, puede identificar clústeres de **forma arbitraria** (como anillos, lunas, etc.), aunque en este ejemplo particular los clústeres son compactos.
- **Manejo del Ruido:** K-means obliga a asignar cada punto a un clúster. El punto aislado $P_9(5, 5)$, que DBSCAN clasifica correctamente como ruido, sería forzosamente asignado al centroide más cercano (probablemente distorsionando la forma o la media de uno de los clústeres principales).
- **Número Fijo de Clústeres:** K-means requiere que el número K sea especificado de antemano. DBSCAN determina el número de clústeres automáticamente a partir de los datos, basándose en la conectividad por densidad.

II. Parte Práctica (70pts)

II-A. Introducción

Los sistemas de recomendación son fundamentales para la personalización de contenidos audiovisuales, tradicionalmente basados en información textual como sinopsis, géneros o valoraciones de usuarios. Sin embargo, el póster de una película constituye una fuente de información visual frecuentemente subestimada, que encapsula aspectos clave del estilo, tono y temática mediante elementos visuales como colores, formas y composición.

Este trabajo tiene como objetivo desarrollar un sistema de recomendación basado en características visuales de pósters cinematográficos. La metodología comprende tres etapas principales: extracción de características mediante descriptores visuales (HOG, HSV y LBP), reducción dimensional para preservar la estructura de los datos evitando la maldición de la alta dimensionalidad, y aplicación de algoritmos de clustering para organizar las películas según similitudes visuales.

El estudio busca demostrar que el análisis de características visuales, combinado con técnicas de aprendizaje no supervisado, puede constituir una alternativa efectiva y complementaria a los enfoques tradicionales de recomendación cinematográfica.

II-B. Dataset

Se nos proporiono un archivo .csv llamado *movies_train.csv*, en la cual podemos encontrar el indentificador de la palícula, su nombre, el género primario, los géneros secundarios y los géneros asociados en forma de *One-Hot Encoding*. Además de un dataset llamado *Links.csv* en el cual tenemos los links de las películas y su id.

Para poder extraer los poster, usamos request a la API de TMDb.

- **movies_train.csv:** Contiene 6819 registros, con su identificador, titulo y One-Hot Encoding para los generos.

- **Links.csv:** Contiene 62423 registros y 3 columnas, donde cada una representa un identificador diferente.

- **movies_train_with_links.csv:** Es la data depúes del Join entre los archivos anteriores, finalmente se filtran los datos vacios en los identificadores y nos quedamos con **unified_movies.csv**

II-C. Extracción de características

Para analizar y comparar los pósters de las películas, cada imagen fue representada mediante un conjunto de características numéricas que capturan propiedades visuales relevantes. Se emplearon tres técnicas complementarias que abarcan diferentes aspectos de la información visual:

- **Espacio de color HSV:** Utilizado para describir la información cromática de manera perceptualmente coherente. El modelo HSV (Hue, Saturation, Value) permite capturar la identidad cromática de cada póster mediante el tono, saturación y brillo, superando las limitaciones del modelo RGB.

- **Descriptores de gradientes orientados (HOG):** Empleado para caracterizar la estructura y formas predominantes en las imágenes. HOG analiza la distribución de gradientes de intensidad, representando contornos y bordes relevantes que pueden asociarse a elementos visuales distintivos como siluetas de personajes y composiciones tipográficas.

- **Local Binary Patterns (LBP):** Incorporado para analizar patrones de textura en las imágenes. LBP codifica variaciones locales de intensidad, identificando características microestructurales que reflejan estilos gráficos específicos, complementando así la información cromática y estructural.

La combinación de estos descriptores generó aproximadamente 2,000 características por póster, balanceando la riqueza informativa con la viabilidad computacional para los procesos posteriores de reducción dimensional y agrupamiento.

II-D. Reducción Dimensional

La extracción de características mediante HSV, LBP y HOG generó aproximadamente 2,000 dimensiones por póster. El análisis de correlación reveló valores predominantemente inferiores a 0.001, sin superar 0.1, indicando alta redundancia y justificando la aplicación de técnicas de reducción dimensional para concentrar la información más representativa.

- **PCA (Principal Component Analysis)** Seleccionado por su capacidad para identificar combinaciones lineales

que maximicen la varianza explicada. Su eficiencia computacional y preservación de la estructura global lo hacen ideal para identificar agrupaciones generales entre películas.

- **NMF (Non-negative Matrix Factorization)** Elegido por su idoneidad en procesamiento de imágenes, donde las representaciones no negativas permiten interpretar componentes como patrones visuales base (tonos, texturas, estructuras compositivas).

- **UMAP (Uniform Manifold Approximation and Projection)** Incorporado para capturar relaciones no lineales entre características visuales, preservando tanto la estructura local como global en espacios de baja dimensión.

- **Combinaciones y configuraciones finales** Se probaron distintas configuraciones con el fin de comparar resultados:

  - NMF (10 dimensiones) + UMAP (2 dimensiones)
  - PCA (95 % de varianza) + UMAP (2 dimensiones)

Esta combinación busca aprovechar las ventajas de la reducción lineal inicial seguida de proyección no lineal, optimizando la representación para el posterior análisis de clustering y visualización.

II-E. Preprocesamiento para la reducción

Para las reducciondes de NMF y PCA, se preprocesaron los datos de manera distinta, más que nada por la naturaleza de los métodos.

- Para la reducción de NMF, las características visuales fueron escaladas al rango $[0, 1]$ utilizando **MinMaxScaler**, generando una matriz X'. No se utilizo ningun otro escalamiento, ya que pueden producir valores negativos.
- La reducción de PCA se basa en la varianzas y correlaciones, por lo que todas las variables deben estar en la misma escala. Para lograr eso utilizamos **StandardScaler** para tener una media igual a 0 y una desviación estándar igual a 1.

Este proceso se puede observar en el Notebook Punto 4 del siguiente Deepnote:

II-F. Técnicas de Visualización y Reducción no lineal

Dado que la matriz W de 10 dimensiones no puede ser visualizada directamente, se probaron dos técnicas adicionales de reducción de dimensionalidad con el fin de generar gráficos 2D y poder transformar la información a dimensiones más pequeñas, tratando de captar la no linealidad de los datos:

1. **Análisis de Componentes Principales (PCA)**: Permite una reducción *lineal* que preserva la máxima varianza global de los datos, ofreciendo una visión general de la estructura.
2. **UMAP** (Uniform Manifold Approximation and Projection): Realiza una reducción *no lineal* que preserva las relaciones locales entre muestras, revelando posibles agrupamientos naturales.

II-G. Resultados Obtenidos

Evaluamos cual sería la mejor reducción a 2 dimensiones, observando la dispersión de los datos.

- **Gráfico 1 (NMF + PCA)**: Se observa que los datos se encuentran mayormente concentrados en el centro del plano, lo que dificulta la aplicación de técnicas de agrupamiento como *K-Means*, *DBSCAN* o *GMM*, debido a la baja separación entre grupos potenciales.

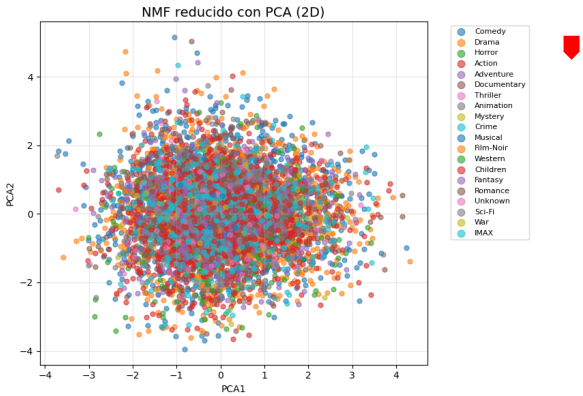

Figura 1. Proyección bidimensional mediante NMF + PCA.

- **Gráfico 2 (NMF + UMAP)**: En contraste, los datos presentan una mayor dispersión en el plano, lo que puede resultar ventajoso para la identificación de posibles clústeres, ya que se aprecia una mejor separación entre las observaciones.

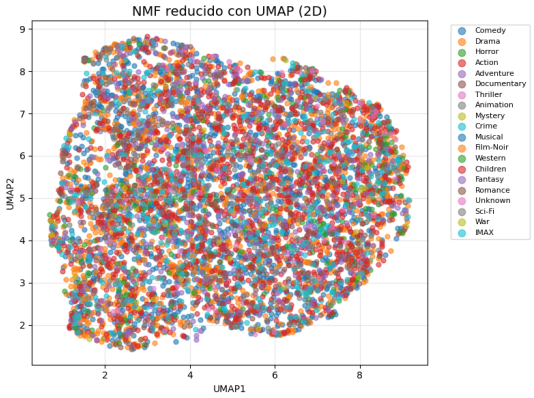

Figura 2. Proyección bidimensional mediante NMF + UMAP.

De esta manera terminamos eligiendo UMAP como método de reducción final para **NMF** debido a su capacidad

para preservar relaciones no lineales y estructuras locales en los datos.

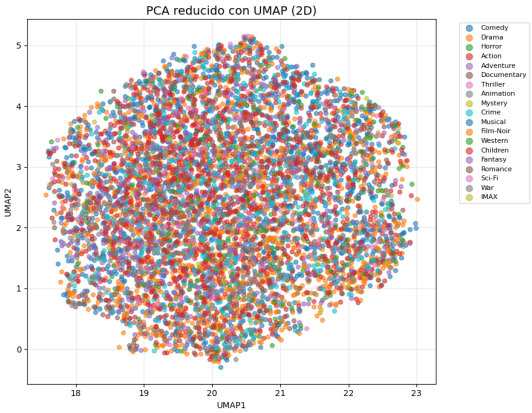

Por cuestiones de experimentación, tambien decidimos utilizar una reducción de UMAP a 3 dimensiones. Ya que queriamos visualizar si el aumentarle en una dimensión cambiaría en algo distribuciones.

II-H. Algoritmos de agrupamiento

Una vez reducida la dimensionalidad de las características visuales, el siguiente paso consistió en aplicar métodos de agrupamiento para identificar patrones o similitudes entre los pósters de las películas. En este trabajo se utilizaron dos enfoques complementarios: K-Means++ y GMM.

1. **K-Means++** El algoritmo K-Means++ es una mejora del tradicional K-Means, diseñada para optimizar la inicialización de los centroides. En lugar de seleccionarlos aleatoriamente, K-Means++ distribuye los centroides iniciales de forma más inteligente, reduciendo la probabilidad de converger hacia soluciones locales y mejorando la estabilidad de los resultados.

2. **GMM**
   Los Modelos de Mezcla Gaussiana (GMM) modelan los datos como una combinación ponderada de distribuciones normales multivariadas, y se ajustan mediante el algoritmo Expectation-Maximization (EM) para estimar las medias, covarianzas y pesos de cada componente (Bishop, 2006; Murphy, 2012).

II-I. Experimentación

Con las reducciones realizadas a 2 y 3 dimensiones con UMAP, para PCA y NMF, procedimos con las experimentación, aquí observamos el rendimiento de los modelos con sus diferentes parametros.

1. **KMeans++**
   El modelo fue desarrollado con los siguientes parámetros principales y con una semilla de 42, para la reproductivilidad:

- **Número de clusters** (k)**:** Se optó por tomar el resultado de aplicar el (*Elbow method*) y la métrica *Silhouette*. Se exploraron valores de k en el rango $[2, 15]$.

Evaluación de desempeño:
Para cada dataset se determinaron los valores óptimos de k según la puntuación *Silhouette* y la inercia total. Se puede apreciar que el mejor Silhouette corresponde a los resultados de la redcción con NMF + UMAP 2D.

- **NMF+UMAP 2D:** $k = 3$, *Silhouette* = 0.4049
- **NMF+UMAP 3D:** $k = 3$, *Silhouette* = 0.3328
- **PCA+UMAP 2D:** $k = 3$, *Silhouette* = 0.3779
- **PCA+UMAP 3D:** $k = 6$, *Silhouette* = 0.2976

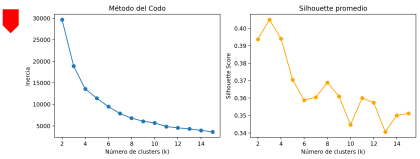

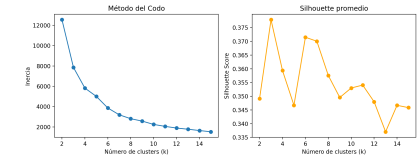

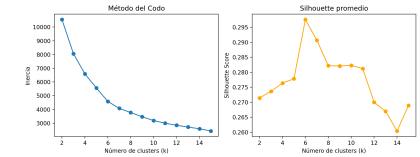

Se observa una relación inversa entre el número de *clusters* y el valor del coeficiente *Silhouette*. A medida que disminuye la cantidad de *clusters*, el valor de *Silhouette* tiende a aumentar, indicando una mayor cohesión interna y una separación más clara entre grupos. Sin embargo, esto implica que las agrupaciones son más generales y menos específicas. Por el contrario, al incrementar el número de *clusters*, el *Silhouette* disminuye, reflejando una mayor precisión en la segmentación, pero con fronteras más difusas entre los grupos. Este comportamiento evidencia el compromiso entre la generalización y la precisión en el proceso de agrupamiento.

II-I1. Modelo GMM con Representaciones NMF-UMAP (2D y 3D): Para la presente sección, se buscó el clustering de cada película en funcoin a las características visuales, mediante un modelo implementado GMM. Así como para Kmeans++, se emplearon los resultados de la dimensión de dimensionalidad tanto con PCA y UMAP, como con NMF y UMAP.

II-I1a. Configuración y parámetros del modelo: Se desarrolló un modelo de mezclas gaussianas (GMM) implementado mediante el algoritmo Expectation-Maximization (EM) para la clusterización no supervisada de producciones cinematográficas utilizando representaciones visuales derivadas de técnicas de reducción dimensional. La implementación contempló la inicialización robusta de parámetros mediante selección aleatoria de muestras representativas del espacio de características UMAP, con matrices de covarianza inicializadas como identidades regularizadas para garantizar estabilidad numérica.

La estrategia de optimización incorporó un proceso iterativo bifásico: en la fase Expectation se computaron las responsabilidades posteriores mediante funciones de densidad de probabilidad multivariadas, mientras que la fase Maximization actualizó los parámetros del modelo ponderando por las asignaciones probabilísticas. Se implementaron mecanismos de suavizado logarítmico y tolerancia a singularidades para asegurar convergencia en espacios de alta dimensionalidad.

La determinación del número óptimo de componentes (k) se abordó mediante evaluación comparativa de criterios de información bayesianos (BIC) y métricas de cohesión intra-cluster (Silhouette). Los resultados indicaron óptimos en k=6 para representaciones bidimensionales y k=8 para el caso tridimensional, con convergencia acelerada alcanzada entre 9-20 iteraciones. El análisis de composición semántica posterior reveló agrupaciones coherentes con dominancia de géneros específicos, validando la capacidad del modelo para capturar patrones visuales subyacentes sin incorporar etiquetado semántico durante el proceso de entrenamiento.

II-I1b. Evaluación y resultados: Para el presente trabajo evaluamos el clustering para 4 escenarios según el tipo de reducción dimensional que fue aplicada previamente. De tal modo a continuación procedemos a explicar los resultados

Caso PCA 2D: El modelo GMM identificó 8 componentes como óptimos según el criterio BIC (41991.10), evidenciando una convergencia progresiva del log-verosimilitud desde -20959.12 hasta -20739.13 a lo largo de 200 iteraciones. La distribución resultante mostró clusters balanceados, con el cluster 5 conteniendo la mayor población (1882 muestras) y el cluster 2 la menor (283 muestras).

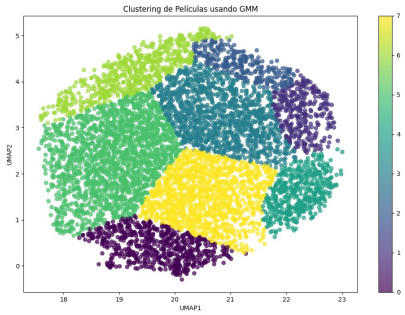

Figura 6. Aplicación PCA 2D

Caso PCA 3D:

La configuración tridimensional determinó 7 componentes óptimos mediante BIC (32004.56), con una mejora sustancial del log-verosimilitud desde -16269.48 hasta -15744.70. El cluster 1 emergió como el más representativo (1682 muestras), mientras el cluster 0 presentó la menor densidad (360 muestras).

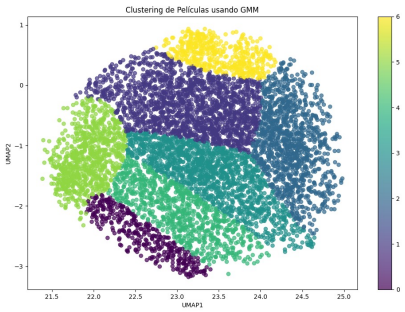

Figura 7. Aplicacion PCA 3D

Caso NMF 2D: El análisis bidimensional con características NMF seleccionó 8 componentes (BIC: 53736.59), alcanzando convergencia rápida con log-verosimilitud final de -26656.78. La distribución cluster mostró predominio del cluster 3 (1821 muestras) y clusters secundarios significativos en las posiciones 6 y 5.

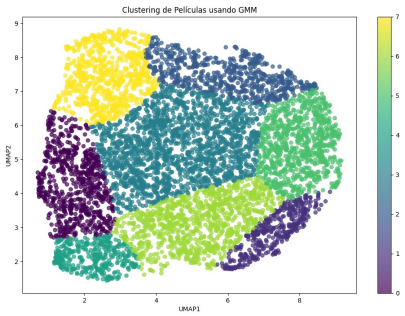

Figura 8. Aplicacion NMF 2D

Caso NMF 3D:

La representación tridimensional NMF confirmó 8 componentes óptimos (BIC: 45181.95), con la mejora más pronunciada en log-verosimilitud desde -22688.13 hasta -22377.44. El cluster 6 demostró máxima densidad (1850 muestras), estableciendo una estructura cluster bien diferenciada.

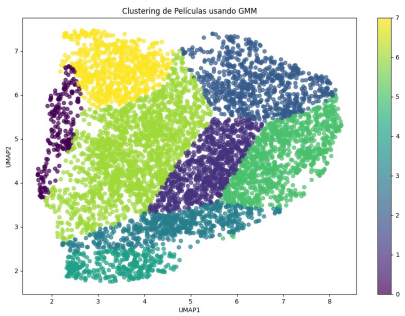

Figura 9. Aplicacion NMF 3D

II-J. Discusión y hallazgos

Gracias a lo previamente apreciado en las visualizaciones y la forma en que fue planteada la estrategia de análisis, se pudo evidenciar cómo todos los casos exhibieron patrones de convergencia consistentes, al tiempo que la distribución *cluster* resultante en todos los escenarios evidenció capacidad para identificar agrupaciones naturales en el espacio de características visuales. Asimismo, si bien las configuraciones NMF generaron valores BIC inferiores, sugiriendo mejor ajuste modelístico, las representaciones en 3D mostraron mayor eficiencia en convergencia, requiriendo menores mejoras iterativas en etapas avanzadas.

En cuanto al algoritmo **KMeans++**, se observó un comportamiento coherente con los valores del coeficiente *Silhouette*, reflejando la calidad de las agrupaciones obtenidas. Se evidenció una relación inversa entre el número de *clusters* y el valor de *Silhouette*: a menor cantidad de grupos, los valores de *Silhouette* aumentaron, indicando una separación más clara pero menos granular; mientras que al incrementar los *clusters*, el *Silhouette* disminuyó, reflejando agrupaciones más específicas pero con fronteras menos definidas. Este compromiso entre generalización y precisión permitió identificar configuraciones óptimas que balancean cohesión y separación dentro del espacio reducido por NMF y UMAP.

II-K. Conclusiones y recomendaciones

1. **Conclusiones** La estrategia de análisis demostró patrones de convergencia consistentes y una identificación efectiva de agrupaciones naturales en el espacio de características visuales. Se observó un equilibrio entre las metodologías empleadas: aunque las configuraciones basadas en NMF mostraron mejores valores BIC —indicando un ajuste modelístico superior—, las representaciones en tres dimensiones ofrecieron una convergencia más eficiente, con menor número de iteraciones requeridas.

   El algoritmo KMeans++, evaluado mediante el coeficiente *Silhouette*, confirmó la calidad de las agrupaciones al evidenciar una relación inversa entre el número de *clusters* y el valor del *Silhouette*. Esto refleja el compromiso entre una segmentación más general (menos *clusters*) y una agrupación más precisa (más *clusters*), permitiendo equilibrar cohesión y separación dentro del espacio reducido por NMF y UMAP.

   Asimismo, se observó que los modelos logran representar parcialmente las similitudes visuales entre algunas películas. En particular, PCA tendió a capturar mejor las variaciones de color, mientras que NMF logró una mejor identificación de composiciones o estructuras visuales. Estos hallazgos resaltan la necesidad de incorporar descriptores visuales adicionales —tales como texturas o formas más complejas— para fortalecer la representación de los pósters y mejorar la coherencia entre los puntos dentro de cada *cluster*.

2. **Recomendaciones:**
   - **Features más detalladas:** Se recomienda obtener un conjunto de características visuales más completo de los pósters, incorporando descriptores adicionales que capturen detalles finos. Esto podría mejorar la diferenciación entre los puntos y aumentar la precisión de los modelos de agrupamiento.

   - **Cantidad de dimensiones:** Se debe considerar cuidadosamente la cantidad de dimensiones utilizadas en la fase de reducción. En los experimentos iniciales, trabajar con 30 y 100 dimensiones generó un alto costo computacional y resultados poco consistentes. Reducir a dimensiones más manejables permitió obtener modelos más estables y eficientes.

   - **Análisis de distribuciones:** Es fundamental observar la distribución de los datos antes de aplicar algoritmos de agrupamiento. Inicialmente se probaron métodos como DBSCAN y dendrogramas jerárquicos sin un análisis exploratorio previo, lo que llevó a resultados subóptimos con valores de *Silhouette* muy bajos o negativos.

   - **Selección de métricas:** Se debe prestar especial atención a las métricas y distancias empleadas. En el caso de KMeans++, el uso de una métrica basada en la similitud del coseno podría haber sido más apropiado que la distancia euclidiana. Asimismo, en el modelo GMM, la utilización del criterio BIC resultó adecuada para la selección automática del número de *clusters*.

REFERENCIAS

II-L. Anexos

- **Notebook del proyecto:** Disponible en la plataforma Deepnote para inspeccionar el proceso de reducción de dimensionalidad y modelado con GMM. Acceder al notebook en Deepnote
- **Streamlit:** Implementación interactiva en Streamlit para visualizar los resultados de la clusterización. Abrir aplicación Streamlit
- **Google Collab:** Implementación del modelo de GMM Acceso al collab
- **Repositorio de código:** Contiene los scripts, dataset procesado y configuración del entorno de ejecución. Repositorio en GitHub